

chapter 1: 线性回归

符号介绍

输入数据 $X = [x^{(1)}, x^{(2)}, \dots, x^{(n)}]^T$
输出标签 $Y = [y^{(1)}, y^{(2)}, \dots, y^{(n)}]^T$
第*i*个输入数据 $x^{(i)}$
第*i*个输出数据 $y^{(i)}$
第*i*个数据的第*j*个特征 $x_j^{(i)} (1 \leq j \leq m)$

概念

- 线性判别分析

知识点

Q1. X必须是满秩的, 倘若不是, 怎么办
A1. 倘若不是满秩的, 则 $X^T X$ 不存在逆, 无法求解, 只能通过正则化限制 θ 的范围来获得可行解

Q2. 正则化的几何意义以及其公式
A2. 见下文推导过程

Q3. 非参数学习算法与参数学习算法的定义, 区别
A3. 定义: 训练完成后是否需要保存训练数据 区别:非参数学习算法训练完成后不需要保存参数(LR), 而参数学习算法需要(LWR)

Q4. 简述LWR算法过程
A4. 代价函数 $J(\theta) = \frac{1}{2} \sum_{i=1}^{i=n} w_i (h_{\theta}(x^{(i)}) - y^{(i)})^2$ 其中 $w_i = \exp(-\frac{(x^{(i)}-x)}{2\gamma^2})$
每当有新数据加入train data时候原数据仍然需要保存

Q5. 二分类问题下逻辑回归的代价函数
A5.

$$h_{\theta}(x) = \frac{1}{1 + e^{\theta^T x}}$$
$$P(y|x; \theta) = (h_{\theta}(x^{(i)}))^{y^{(i)}} (1 - h_{\theta}(x^{(i)}))^{1-y^{(i)}}$$
$$J(\theta) = \log L(\theta) = \prod_{i=1}^{i=n} \log P(y|x, \theta) = \sum_{i=1}^{i=n} y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))$$

$P(y|x, \theta)$ 与 $P(y|x; \theta)$ 区别: 前者 θ 是变量而后者是常量或者给定值

Q6. 牛顿法的求解过程
A6. 牛顿法采用不断迭代 $x_{(i+1)} = x_i - \frac{f^{i\text{阶导数}}(x_i)}{f^{i+1\text{阶导数}}(x_{(i+1)})}$ 求解出代价函数导数的零点获得最优解

Q7. 从二分类到多分类的几种方法以及其各自的优缺点
A7. 1对其余: 分出单独某一类以及其他类; 1对1: 区分待判定样本是第*i*类还是第*j*类(需要 $n(n - 1)/2$ 个分类器然后再统计最高票数)

Q8. 简述LDA的算法过程
A8. 面试不常考,在此仅仅给出引用, 西瓜书P60

公式推导以及证明

预备知识: (需翻墙)

矩阵的迹

矩阵求导

- 线性回归问题描述以及采用LMS作为cost function其最优解

假设函数

$$h_{\theta}(x)=\sum_{i=1}^{i=m}\theta_ix_i=\theta^Tx$$

代价函数

$$\begin{aligned} J(\theta) &= \frac{1}{2} \sum_{i=1}^{i=n} (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \frac{1}{2} \sum_{i=1}^{i=n} (\theta^Tx^{(i)} - y^{(i)})^2 \\ \nabla_{\theta}J(\theta) &= \frac{1}{2} \nabla_{\theta}(X\theta - Y)^T(X\theta - Y) \\ &= \frac{1}{2} \nabla_{\theta}tr(\theta^TX^TX\theta - Y^TX\theta - \theta^TX^TY + Y^TY) \\ &= \frac{1}{2} \nabla_{\theta}tr(\theta^TX^TX\theta - 2Y^TX\theta) \\ &= \frac{1}{2} \nabla_{\theta}tr(\theta^TX^TX\theta - 2Y^TX\theta) \\ &= \frac{1}{2} tr(X^TX\theta + \theta^TX^TX^T - 2Y^TX) \\ &= X^TX\theta + Y^TX \\ &= X^TX\theta + X^TY \end{aligned}$$

令 $\nabla_{\theta}J(\theta) = 0$ 可得

$$\theta = (X^TX)^{-1}X^TY$$

- 加入L1, L2正则其表达式以及其最优解

$$J(\theta) = \frac{1}{2} (X\theta - Y)^T(X\theta - Y) + \frac{\lambda}{2} \sum_{j=1}^{j=n} |\theta_j|^q$$

采用拉格朗日乘子可得

$$\theta = (X^TX)^{-1}X^TY \quad \text{s.t.} \sum_{j=1}^{j=n} |\theta_j|^q < \lambda$$

- 使用概率的方法推导LR求解过程 $y^{(i)} = \theta^Tx^{(i)} + \epsilon^{(i)}$ 其中 $\epsilon^{(i)}$ 表示经验误差或者非模型影响因素。由于 $y^{(i)}$ 的分布与 ϵ 保持一致,则有

$$P(y^{(i)}|x^{(i)};\theta) = \frac{1}{\sqrt{2\pi}\sigma} \exp(-\frac{(y^{(i)} - \theta^Tx^{(i)})^2}{2\sigma^2})$$

采用MLE作为代价函数可得:

$$\begin{aligned}
 J(\theta) &= L(\theta) = \log \prod_{i=1}^{i=n} P(y^{(i)} | x^{(i)}; \theta) \\
 &= \sum_{i=1}^{i=n} \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right) \\
 &= n \log \frac{1}{\sqrt{2\pi}\sigma} + \frac{1}{2\sigma^2} \sum_{i=1}^{i=n} (y^{(i)} - \theta^T x)^2
 \end{aligned}$$

由上可知, 采用MLE的方法计算LR与LMS做为代价函数是等价的